

Lab 3: Embedding trong Xử lý Ngôn ngữ Tự nhiên (NLP)

Bài lab: Trực quan hóa và Phân tích Word Embeddings

Mục tiêu:

- Khảo sát các mô hình embedding: Word2Vec, GloVe, fastText
- Giảm Chiều Vector: Thực hiện giảm chiều cho các vector dày đặc (dense vectors) từ tập từ điển của các mô hình Word2Vec, GloVe, hoặc fastText xuống còn 2 chiều (2D) hoặc 3 chiều (3D).
- Trực quan hóa các từ trong không gian vector
- Tìm kiếm Top K từ tương đồng

1. Cài đặt thư viện

Cài đặt các thư viện cần thiết để làm việc với embeddings

```
In [ ]: # Cài đặt các thư viện cần thiết
!pip install gensim numpy pandas matplotlib seaborn scikit-learn plotly -q
```

2. Import các thư viện

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.decomposition import PCA
from sklearn.manifold import TSNE
from sklearn.metrics.pairwise import cosine_similarity
import gensim.downloader as api
from gensim.models import KeyedVectors
import plotly.graph_objects as go
import plotly.express as px
import warnings
warnings.filterwarnings('ignore')

# Cấu hình hiển thị
plt.style.use('seaborn-v0_8-darkgrid')
sns.set_palette("husl")
%matplotlib inline

print("Đã import thành công tất cả các thư viện!")
```

Đã import thành công tất cả các thư viện!

3. Load Pre-trained Embeddings

Tai cac mo hinh pre-trained tu Gensim

```
In [3]: # Hien thi cac model co san
print("Cac model embedding co san:")
print("-" * 50)
available_models = api.info()['models']
for name, info in available_models.items():
    if 'word2vec' in name or 'glove' in name or 'fasttext' in name:
        print(f"- {name}: {info.get('description', 'N/A')[:80]}...")
```

Cac model embedding co san:

```
-----
- fasttext-wiki-news-subwords-300: 1 million word vectors trained on Wikipedia 2017,
UMBC webbase corpus and statmt...
- word2vec-ruscorpora-300: Word2vec Continuous Skipgram vectors trained on full Russ
ian National Corpus (ab...
- word2vec-google-news-300: Pre-trained vectors trained on a part of the Google News
dataset (about 100 bill...
- glove-wiki-gigaword-50: Pre-trained vectors based on Wikipedia 2014 + Gigaword, 5.
6B tokens, 400K vocab,...
- glove-wiki-gigaword-100: Pre-trained vectors based on Wikipedia 2014 + Gigaword 5.
6B tokens, 400K vocab, ...
- glove-wiki-gigaword-200: Pre-trained vectors based on Wikipedia 2014 + Gigaword,
5.6B tokens, 400K vocab,...
- glove-wiki-gigaword-300: Pre-trained vectors based on Wikipedia 2014 + Gigaword,
5.6B tokens, 400K vocab,...
- glove-twitter-25: Pre-trained vectors based on 2B tweets, 27B tokens, 1.2M vocab,
uncased (https:/...
- glove-twitter-50: Pre-trained vectors based on 2B tweets, 27B tokens, 1.2M vocab,
uncased (https:/...
- glove-twitter-100: Pre-trained vectors based on 2B tweets, 27B tokens, 1.2M voca
b, uncased (https:...
- glove-twitter-200: Pre-trained vectors based on 2B tweets, 27B tokens, 1.2M vocab,
uncased (https:/...
- __testing_word2vec-matrix-synopsis: [THIS IS ONLY FOR TESTING] Word vecrors of the
movie matrix....
```

```
In [5]: # Load Word2Vec (Google News - 300 dimensions)
print("Dang tai Word2Vec model...")
word2vec_model = api.load('word2vec-google-news-300')
print(f"Word2Vec loaded: {len(word2vec_model)} words, {word2vec_model.vector_size}

# Load GloVe (Wikipedia + Gigaword - 300 dimensions)
print("\nDang tai GloVe model...")
glove_model = api.load('glove-wiki-gigaword-300')
print(f"GloVe loaded: {len(glove_model)} words, {glove_model.vector_size} dimension

# Load fastText (Wikipedia - 300 dimensions)
print("\nDang tai fastText model...")
fasttext_model = api.load('fasttext-wiki-news-subwords-300')
print(f"fastText loaded: {len(fasttext_model)} words, {fasttext_model.vector_size}
```

Dang tai Word2Vec model...
Word2Vec loaded: 3000000 words, 300 dimensions

Dang tai GloVe model...
GloVe loaded: 400000 words, 300 dimensions

Dang tai fastText model...
fastText loaded: 999999 words, 300 dimensions

4. Khảo sát cơ bản Embeddings

Kiểm tra các thuộc tính của embeddings

```
In [17]: # Chọn một số từ để khảo sát
test_words = ['king', 'queen', 'man', 'woman', 'computer', 'science', 'python', 'programming']

print("Kiểm tra các từ có trong vocabulary:")
print("=" * 60)
for word in test_words:
    w2v = word in word2vec_model
    glv = word in glove_model
    ft = word in fasttext_model
    print(f"{word:15s} - Word2Vec: {w2v}, GloVe: {glv}, fastText: {ft}")
```

Kiểm tra các từ có trong vocabulary:

```
=====
king           - Word2Vec: True, GloVe: True, fastText: True
queen          - Word2Vec: True, GloVe: True, fastText: True
man            - Word2Vec: True, GloVe: True, fastText: True
woman          - Word2Vec: True, GloVe: True, fastText: True
computer       - Word2Vec: True, GloVe: True, fastText: True
science        - Word2Vec: True, GloVe: True, fastText: True
python         - Word2Vec: True, GloVe: True, fastText: True
programming    - Word2Vec: True, GloVe: True, fastText: True
```

```
In [7]: # Hiện thị vector của một từ
sample_word = 'computer'

print(f"Vector của từ '{sample_word}' (10 giá trị đầu tiên):")
print("=" * 60)
print(f"Word2Vec: {word2vec_model[sample_word][:10]}")
print(f"GloVe: {glove_model[sample_word][:10]}")
print(f"fastText: {fasttext_model[sample_word][:10]}")
```

Vector của từ 'computer' (10 giá trị đầu tiên):

```
=====
Word2Vec: [ 0.10742188 -0.20117188  0.12304688  0.21191406 -0.09130859  0.21679688
 -0.13183594  0.08300781  0.20214844  0.04785156]
GloVe: [-0.27628  0.13999  0.098519 -0.64019  0.031988  0.10066 -0.18673
 -0.37129  0.5974 -2.0405 ]
fastText: [-0.089791 -0.017821 -0.037268 -0.013295 -0.0090625 -0.03825
 -0.026104 -0.089276  0.051467 -0.0021857]
```

5. Tìm kiếm Top K vector tương đồng

Su dung cosine similarity de tim cac tu gan nghĩa nhất

```
In [8]: def find_similar_words(model, word, top_k=10):
        """
        Tìm top K tu tương đồng nhất với tu cho trước
        """
        if word not in model:
            return None

        similar_words = model.most_similar(word, topn=top_k)
        return similar_words

def compare_similarities(word, top_k=10):
    """
    So sánh kết quả tìm kiếm tu tương đồng giữa các model
    """
    print(f"\nTop {top_k} tu tương đồng với '{word}':")
    print("=" * 80)

    # Word2Vec
    print("\nWord2Vec:")
    w2v_similar = find_similar_words(word2vec_model, word, top_k)
    if w2v_similar:
        for i, (similar_word, score) in enumerate(w2v_similar, 1):
            print(f" {i:2d}. {similar_word:20s} (similarity: {score:.4f})")

    # GloVe
    print("\nGloVe:")
    glove_similar = find_similar_words(glove_model, word, top_k)
    if glove_similar:
        for i, (similar_word, score) in enumerate(glove_similar, 1):
            print(f" {i:2d}. {similar_word:20s} (similarity: {score:.4f})")

    # fastText
    print("\nfastText:")
    ft_similar = find_similar_words(fasttext_model, word, top_k)
    if ft_similar:
        for i, (similar_word, score) in enumerate(ft_similar, 1):
            print(f" {i:2d}. {similar_word:20s} (similarity: {score:.4f})")

    return w2v_similar, glove_similar, ft_similar
```

```
In [9]: # Test với một số từ
test_queries = ['king', 'computer', 'happy']

for query in test_queries:
    compare_similarities(query, top_k=10)
```

Top 10 tu tuong dong voi 'king':

=====

Word2Vec:

- | | |
|-----------------|----------------------|
| 1. kings | (similarity: 0.7138) |
| 2. queen | (similarity: 0.6511) |
| 3. monarch | (similarity: 0.6413) |
| 4. crown_prince | (similarity: 0.6204) |
| 5. prince | (similarity: 0.6160) |
| 6. sultan | (similarity: 0.5865) |
| 7. ruler | (similarity: 0.5798) |
| 8. princes | (similarity: 0.5647) |
| 9. Prince_Paras | (similarity: 0.5433) |
| 10. throne | (similarity: 0.5422) |

GloVe:

- | | |
|------------|----------------------|
| 1. queen | (similarity: 0.6336) |
| 2. prince | (similarity: 0.6197) |
| 3. monarch | (similarity: 0.5900) |
| 4. kingdom | (similarity: 0.5791) |
| 5. throne | (similarity: 0.5606) |
| 6. ii | (similarity: 0.5562) |
| 7. iii | (similarity: 0.5503) |
| 8. crown | (similarity: 0.5225) |
| 9. reign | (similarity: 0.5217) |
| 10. kings | (similarity: 0.5066) |

fastText:

- | | |
|------------------|----------------------|
| 1. king- | (similarity: 0.7838) |
| 2. boy-king | (similarity: 0.7705) |
| 3. queen | (similarity: 0.7704) |
| 4. prince | (similarity: 0.7701) |
| 5. kings | (similarity: 0.7669) |
| 6. sub-king | (similarity: 0.7391) |
| 7. monarch | (similarity: 0.7368) |
| 8. king-making | (similarity: 0.7289) |
| 9. ex-king | (similarity: 0.7280) |
| 10. warrior-king | (similarity: 0.7232) |

Top 10 tu tuong dong voi 'computer':

=====

Word2Vec:

- | | |
|------------------------------|----------------------|
| 1. computers | (similarity: 0.7979) |
| 2. laptop | (similarity: 0.6640) |
| 3. laptop_computer | (similarity: 0.6549) |
| 4. Computer | (similarity: 0.6473) |
| 5. com_puter | (similarity: 0.6082) |
| 6. technician_Leonard_Luchko | (similarity: 0.5663) |
| 7. mainframes_minicomputers | (similarity: 0.5618) |
| 8. laptop_computers | (similarity: 0.5585) |
| 9. PC | (similarity: 0.5540) |
| 10. maker_Dell_DELL.O | (similarity: 0.5519) |

GloVe:

- | | |
|--------------|----------------------|
| 1. computers | (similarity: 0.8248) |
|--------------|----------------------|

- | | |
|---------------|----------------------|
| 2. software | (similarity: 0.7334) |
| 3. pc | (similarity: 0.6240) |
| 4. technology | (similarity: 0.6199) |
| 5. computing | (similarity: 0.6179) |
| 6. laptop | (similarity: 0.5956) |
| 7. internet | (similarity: 0.5858) |
| 8. ibm | (similarity: 0.5825) |
| 9. systems | (similarity: 0.5745) |
| 10. hardware | (similarity: 0.5729) |

fastText:

- | | |
|-------------------|----------------------|
| 1. computers | (similarity: 0.8473) |
| 2. non-computer | (similarity: 0.8157) |
| 3. mini-computer | (similarity: 0.8100) |
| 4. micro-computer | (similarity: 0.7728) |
| 5. super-computer | (similarity: 0.7625) |
| 6. pre-computer | (similarity: 0.7617) |
| 7. computer | (similarity: 0.7486) |
| 8. computery | (similarity: 0.7484) |
| 9. home-computer | (similarity: 0.7476) |
| 10. computerless | (similarity: 0.7416) |

Top 10 từ tương đồng với 'happy':

=====

Word2Vec:

- | | |
|-----------------|----------------------|
| 1. glad | (similarity: 0.7409) |
| 2. pleased | (similarity: 0.6632) |
| 3. ecstatic | (similarity: 0.6627) |
| 4. overjoyed | (similarity: 0.6599) |
| 5. thrilled | (similarity: 0.6514) |
| 6. satisfied | (similarity: 0.6438) |
| 7. proud | (similarity: 0.6360) |
| 8. delighted | (similarity: 0.6272) |
| 9. disappointed | (similarity: 0.6270) |
| 10. excited | (similarity: 0.6248) |

GloVe:

- | | |
|--------------|----------------------|
| 1. 'm | (similarity: 0.7080) |
| 2. glad | (similarity: 0.6905) |
| 3. pleased | (similarity: 0.6712) |
| 4. really | (similarity: 0.6576) |
| 5. always | (similarity: 0.6495) |
| 6. everyone | (similarity: 0.6449) |
| 7. everybody | (similarity: 0.6344) |
| 8. feel | (similarity: 0.6337) |
| 9. i | (similarity: 0.6298) |
| 10. sure | (similarity: 0.6291) |

fastText:

- | | |
|----------------|----------------------|
| 1. happpy | (similarity: 0.8086) |
| 2. happy- | (similarity: 0.7918) |
| 3. happy-happy | (similarity: 0.7885) |
| 4. unhappy | (similarity: 0.7820) |
| 5. happier | (similarity: 0.7645) |
| 6. glad | (similarity: 0.7579) |

7. happy-sad	(similarity: 0.7398)
8. happy.	(similarity: 0.7398)
9. chappy	(similarity: 0.7297)
10. thankful	(similarity: 0.7225)

6. Analogy Task

Kiểm tra khả năng thực hiện phép tương tự: $A - B + C = D$

Vi dụ: king - man + woman = queen

```
In [10]: def test_analogy(model, positive, negative, model_name="Model"):
        """
        Test analogy: positive[0] - negative[0] + positive[1] = ?
        """
        try:
            result = model.most_similar(positive=positive, negative=negative, topn=5)
            print(f"\n{model_name}:")
            print(f" {positive[0]} - {negative[0]} + {positive[1]} = ?")
            for word, score in result:
                print(f"    -> {word} (score: {score:.4f})")
            return result
        except:
            print(f"\n{model_name}: Không thể thực hiện analogy")
            return None

# Test các analogy task
print("Analogy Tasks:")
print("=" * 80)

# king - man + woman = queen
print("\n1. Gender analogy:")
test_analogy(word2vec_model, ['king', 'woman'], ['man'], "Word2Vec")
test_analogy(glove_model, ['king', 'woman'], ['man'], "GloVe")
test_analogy(fasttext_model, ['king', 'woman'], ['man'], "fastText")

# Paris - France + Italy = Rome
print("\n2. Capital-Country analogy:")
test_analogy(word2vec_model, ['Paris', 'Italy'], ['France'], "Word2Vec")
test_analogy(glove_model, ['Paris', 'Italy'], ['France'], "GloVe")
test_analogy(fasttext_model, ['Paris', 'Italy'], ['France'], "fastText")
```

Analogy Tasks:

=====

1. Gender analogy:

Word2Vec:

```
king - man + woman = ?  
-> queen (score: 0.7118)  
-> monarch (score: 0.6190)  
-> princess (score: 0.5902)  
-> crown_prince (score: 0.5499)  
-> prince (score: 0.5377)
```

GloVe:

```
king - man + woman = ?  
-> queen (score: 0.6713)  
-> princess (score: 0.5433)  
-> throne (score: 0.5386)  
-> monarch (score: 0.5348)  
-> daughter (score: 0.4980)
```

fastText:

```
king - man + woman = ?  
-> queen (score: 0.7787)  
-> queen-mother (score: 0.7144)  
-> king- (score: 0.6981)  
-> queen-consort (score: 0.6725)  
-> monarch (score: 0.6667)
```

2. Capital-Country analogy:

Word2Vec:

```
Paris - France + Italy = ?  
-> Milan (score: 0.7222)  
-> Rome (score: 0.7028)  
-> Palermo_Sicily (score: 0.5968)  
-> Italian (score: 0.5911)  
-> Tuscany (score: 0.5633)
```

GloVe: Không thể thực hiện analogy

fastText:

```
Paris - France + Italy = ?  
-> Rome (score: 0.7744)  
-> Milan (score: 0.7696)  
-> Bologna (score: 0.7657)  
-> Naples (score: 0.7545)  
-> Venice (score: 0.7300)
```

```
Out[10]: [('Rome', 0.7743859887123108),  
          ('Milan', 0.7696377038955688),  
          ('Bologna', 0.7657278776168823),  
          ('Naples', 0.7544800639152527),  
          ('Venice', 0.7299832105636597)]
```

7. Chuẩn bị dữ liệu - PCA

Chọn một tập các từ để trực quan hóa

```
In [11]: # Định nghĩa các nhóm từ để trực quan hóa
word_groups = {
    'Royalty': ['king', 'queen', 'prince', 'princess', 'monarch', 'crown'],
    'Family': ['man', 'woman', 'boy', 'girl', 'father', 'mother', 'son', 'daughter'],
    'Technology': ['computer', 'software', 'hardware', 'internet', 'programming', ''],
    'Science': ['physics', 'chemistry', 'biology', 'mathematics', 'research', 'expe'],
    'Emotions': ['happy', 'sad', 'angry', 'excited', 'fear', 'joy'],
    'Animals': ['cat', 'dog', 'bird', 'fish', 'elephant', 'lion']
}

# Tao danh sach tat ca cac tu
all_words = []
word_labels = []
for group, words in word_groups.items():
    all_words.extend(words)
    word_labels.extend([group] * len(words))

print(f"Tổng số từ để trực quan hóa: {len(all_words)}")
print(f"Các nhóm: {list(word_groups.keys())}")
```

Tổng số từ để trực quan hóa: 38

Các nhóm: ['Royalty', 'Family', 'Technology', 'Science', 'Emotions', 'Animals']

```
In [12]: def get_vectors_for_words(model, words):
    """
    Lấy vectors cho danh sách các từ
    """
    vectors = []
    valid_words = []
    valid_labels = []

    for word, label in zip(words, word_labels):
        if word in model:
            vectors.append(model[word])
            valid_words.append(word)
            valid_labels.append(label)

    return np.array(vectors), valid_words, valid_labels

# Lay vectors cho cac model
print("Đang truy xuất vectors...")
w2v_vectors, w2v_words, w2v_labels = get_vectors_for_words(word2vec_model, all_words)
glove_vectors, glove_words, glove_labels = get_vectors_for_words(glove_model, all_words)
ft_vectors, ft_words, ft_labels = get_vectors_for_words(fasttext_model, all_words)

print(f"\nWord2Vec: {len(w2v_words)} words, shape {w2v_vectors.shape}")
print(f"GloVe: {len(glove_words)} words, shape {glove_vectors.shape}")
print(f"fastText: {len(ft_words)} words, shape {ft_vectors.shape}")
```

Đang truy xuất vectors...

Word2Vec: 38 words, shape (38, 300)

GloVe: 38 words, shape (38, 300)

fastText: 38 words, shape (38, 300)

8. Giảm chiều với PCA (2D va 3D)

Sử dụng PCA để giảm từ 300D xuống 2D và 3D

```
In [13]: def apply_pca(vectors, n_components=2):
        """
        Áp dụng PCA để giảm chiều
        """
        pca = PCA(n_components=n_components, random_state=42)
        reduced_vectors = pca.fit_transform(vectors)
        explained_variance = pca.explained_variance_ratio_

        print(f"PCA {n_components}D:")
        print(f"    Explained variance ratio: {explained_variance}")
        print(f"    Total explained variance: {sum(explained_variance):.4f}")

        return reduced_vectors, explained_variance

# Áp dụng PCA 2D
print("\nWord2Vec - PCA 2D:")
w2v_pca_2d, w2v_pca_2d_var = apply_pca(w2v_vectors, n_components=2)

print("\nGloVe - PCA 2D:")
glove_pca_2d, glove_pca_2d_var = apply_pca(glove_vectors, n_components=2)

print("\nfastText - PCA 2D:")
ft_pca_2d, ft_pca_2d_var = apply_pca(ft_vectors, n_components=2)

# Áp dụng PCA 3D
print("\n" + "="*60)
print("\nWord2Vec - PCA 3D:")
w2v_pca_3d, w2v_pca_3d_var = apply_pca(w2v_vectors, n_components=3)

print("\nGloVe - PCA 3D:")
glove_pca_3d, glove_pca_3d_var = apply_pca(glove_vectors, n_components=3)

print("\nfastText - PCA 3D:")
ft_pca_3d, ft_pca_3d_var = apply_pca(ft_vectors, n_components=3)
```

```
Word2Vec - PCA 2D:
PCA 2D:
  Explained variance ratio: [0.13853201 0.09164825]
  Total explained variance: 0.2302
```

```
GloVe - PCA 2D:
PCA 2D:
  Explained variance ratio: [0.17433242 0.09558851]
  Total explained variance: 0.2699
```

```
fastText - PCA 2D:
PCA 2D:
  Explained variance ratio: [0.15067215 0.12634432]
  Total explained variance: 0.2770
```

=====

```
Word2Vec - PCA 3D:
PCA 3D:
  Explained variance ratio: [0.13853201 0.09164825 0.08893836]
  Total explained variance: 0.3191
```

```
GloVe - PCA 3D:
PCA 3D:
  Explained variance ratio: [0.17433242 0.09558851 0.08511987]
  Total explained variance: 0.3550
```

```
fastText - PCA 3D:
PCA 3D:
  Explained variance ratio: [0.15067215 0.12634432 0.09945986]
  Total explained variance: 0.3765
```

9. Giảm chiều với t-SNE (2D và 3D)

Sử dụng t-SNE để giảm chiều - tốt hơn cho visualization

```
In [14]: from sklearn.manifold import TSNE

def apply_tsne(vectors, n_components=2, perplexity=30):
    """
    Áp dụng t-SNE để giảm chiều
    """
    tsne = TSNE(
        n_components=n_components,
        perplexity=perplexity,
        random_state=42,
        max_iter=1000,
        verbose=1
    )
    reduced_vectors = tsne.fit_transform(vectors)
    return reduced_vectors

# Áp dụng t-SNE 2D
```

```
print("Word2Vec - t-SNE 2D:")
w2v_tsne_2d = apply_tsne(w2v_vectors, n_components=2)

print("\nGloVe - t-SNE 2D:")
glove_tsne_2d = apply_tsne(glove_vectors, n_components=2)

print("\nfastText - t-SNE 2D:")
ft_tsne_2d = apply_tsne(ft_vectors, n_components=2)

# Áp dụng t-SNE 3D
print("\n" + "-"*60)
print("\nWord2Vec - t-SNE 3D:")
w2v_tsne_3d = apply_tsne(w2v_vectors, n_components=3)

print("\nGloVe - t-SNE 3D:")
glove_tsne_3d = apply_tsne(glove_vectors, n_components=3)

print("\nfastText - t-SNE 3D:")
ft_tsne_3d = apply_tsne(ft_vectors, n_components=3)
```

Word2Vec - t-SNE 2D:

```
[t-SNE] Computing 37 nearest neighbors...
[t-SNE] Indexed 38 samples in 0.005s...
[t-SNE] Computed neighbors for 38 samples in 2.462s...
[t-SNE] Computed conditional probabilities for sample 38 / 38
[t-SNE] Mean sigma: 2.206233
[t-SNE] KL divergence after 250 iterations with early exaggeration: 40.768456
[t-SNE] KL divergence after 800 iterations: 0.044528
```

GloVe - t-SNE 2D:

```
[t-SNE] Computing 37 nearest neighbors...
[t-SNE] Indexed 38 samples in 0.000s...
[t-SNE] Computed neighbors for 38 samples in 0.014s...
[t-SNE] Computed conditional probabilities for sample 38 / 38
[t-SNE] Mean sigma: 5.085953
[t-SNE] KL divergence after 250 iterations with early exaggeration: 48.882404
[t-SNE] KL divergence after 850 iterations: 0.040583
```

fastText - t-SNE 2D:

```
[t-SNE] Computing 37 nearest neighbors...
[t-SNE] Indexed 38 samples in 0.000s...
[t-SNE] Computed neighbors for 38 samples in 0.012s...
[t-SNE] Computed conditional probabilities for sample 38 / 38
[t-SNE] Mean sigma: 0.762251
[t-SNE] KL divergence after 250 iterations with early exaggeration: 43.306789
[t-SNE] KL divergence after 1000 iterations: 0.031236
```

Word2Vec - t-SNE 3D:

```
[t-SNE] Computing 37 nearest neighbors...
[t-SNE] Indexed 38 samples in 0.000s...
[t-SNE] Computed neighbors for 38 samples in 0.014s...
[t-SNE] Computed conditional probabilities for sample 38 / 38
[t-SNE] Mean sigma: 2.206233
[t-SNE] KL divergence after 250 iterations with early exaggeration: 133.357208
[t-SNE] KL divergence after 1000 iterations: 0.763281
```

GloVe - t-SNE 3D:

```
[t-SNE] Computing 37 nearest neighbors...
[t-SNE] Indexed 38 samples in 0.000s...
[t-SNE] Computed neighbors for 38 samples in 0.012s...
[t-SNE] Computed conditional probabilities for sample 38 / 38
[t-SNE] Mean sigma: 5.085953
[t-SNE] KL divergence after 250 iterations with early exaggeration: 106.598709
[t-SNE] KL divergence after 1000 iterations: 0.818125
```

fastText - t-SNE 3D:

```
[t-SNE] Computing 37 nearest neighbors...
[t-SNE] Indexed 38 samples in 0.001s...
[t-SNE] Computed neighbors for 38 samples in 0.013s...
[t-SNE] Computed conditional probabilities for sample 38 / 38
[t-SNE] Mean sigma: 0.762251
[t-SNE] KL divergence after 250 iterations with early exaggeration: 107.419411
[t-SNE] KL divergence after 1000 iterations: 0.692199
```

10. Trực quan hóa 2D với PCA

```
In [15]: def plot_2d_embeddings(coords, words, labels, title, method="PCA"):
    """
    Vẽ biểu đồ 2D cho embeddings
    """
    fig, ax = plt.subplots(figsize=(14, 10))

    # Tạo color map
    unique_labels = list(set(labels))
    colors = plt.cm.tab10(np.linspace(0, 1, len(unique_labels)))
    color_map = {label: colors[i] for i, label in enumerate(unique_labels)}

    # Vẽ các điểm
    for label in unique_labels:
        mask = np.array(labels) == label
        ax.scatter(coords[mask, 0], coords[mask, 1],
                   c=[color_map[label]], label=label, s=100, alpha=0.6, edgecolors='r')

    # Thêm Label cho các điểm
    for i, word in enumerate(words):
        ax.annotate(word, (coords[i, 0], coords[i, 1]),
                   fontsize=9, alpha=0.8, ha='center')

    ax.set_xlabel(f'{method} Component 1', fontsize=12)
    ax.set_ylabel(f'{method} Component 2', fontsize=12)
    ax.set_title(title, fontsize=14, fontweight='bold')
    ax.legend(loc='best', fontsize=10)
    ax.grid(True, alpha=0.3)

    plt.tight_layout()
    return fig

# Vẽ PCA 2D cho các model
fig1 = plot_2d_embeddings(w2v_pca_2d, w2v_words, w2v_labels,
                        'Word2Vec Embeddings - PCA 2D', 'PCA')
plt.show()

fig2 = plot_2d_embeddings(glove_pca_2d, glove_words, glove_labels,
                        'GloVe Embeddings - PCA 2D', 'PCA')
plt.show()

fig3 = plot_2d_embeddings(ft_pca_2d, ft_words, ft_labels,
                        'fastText Embeddings - PCA 2D', 'PCA')
plt.show()
```

[illegible]


PCA Component 2

PCA Component 1

Legend:

- Family (Blue)
- Animals (Green)
- Science (Purple)
- Royalty (Pink)
- Technology (Yellow)
- Emotions (Cyan)

Word	Category	PCA Component 1	PCA Component 2
software	Technology	-4.2	2.8
hardware	Technology	-3.2	2.2
internet	Technology	-2.2	2.4
computer	Technology	-3.8	1.5
algorithm	Technology	-3.5	1.3
programming	Technology	-3.0	1.2
experiment	Science	-2.2	0.3
research	Science	-3.5	-0.7
biology	Science	-4.2	-3.0
mathematics	Science	-4.2	-3.4
chemistry	Science	-3.8	-3.4
physics	Science	-4.8	-3.7
elephant	Animals	1.5	2.5
lion	Animals	0.8	2.1
giraffe	Animals	1.2	2.4
tiger	Animals	-0.2	1.9
lioness	Animals	1.5	1.6
king	Royalty	1.8	0.8
queen	Royalty	2.5	-2.4
prince	Royalty	2.7	-2.3
princess	Royalty	3.4	-2.2
father	Family	2.5	-1.3
mother	Family	2.2	-0.9
brother	Family	2.7	-1.4
sister	Family	2.8	-1.4
uncle	Family	2.4	-1.3
aunt	Family	2.3	-1.3
grandfather	Family	2.6	-1.4
grandmother	Family	2.5	-1.4
husband	Family	2.2	-1.3
wife	Family	2.3	-1.3
parent	Family	2.4	-1.3
child	Family	2.5	-1.3
family	Family	1.8	-1.2
love	Emotions	1.5	0.6
happiness	Emotions	1.2	0.9
joy	Emotions	1.3	0.9
sadness	Emotions	0.8	0.3
anger	Emotions	0.5	0.3
fear	Emotions	0.2	0.3
surprise	Emotions	0.8	0.5
disgust	Emotions	1.2	0.5
calm	Emotions	1.5	0.6
excited	Emotions	0.2	0.2
relaxed	Emotions	-0.2	0.2
stressed	Emotions	0.5	0.3
happy	Emotions	0.8	0.8
sorry	Emotions	1.2	0.9
grateful	Emotions	1.5	0.6
hopeful	Emotions	1.8	0.8
optimistic	Emotions	2.2	0.0
pessimistic	Emotions	2.5	-0.7
anxious	Emotions	2.8	-1.4
calm	Emotions	2.5	-1.3



12. Trực quan hóa 3D với PCA (Interactive)

```
In [29]: import os
from mpl_toolkits.mplot3d import Axes3D

def plot_3d_interactive(coords, words, labels, title, save_path=None):
    """
    Vẽ biểu đồ 3D với Matplotlib và lưu thành ảnh PNG
    """
    # Tạo figure và 3D axis
    fig = plt.figure(figsize=(14, 10))
    ax = fig.add_subplot(111, projection='3d')

    # Tạo color map
    unique_labels = list(set(labels))
    colors = plt.cm.tab10(np.linspace(0, 1, len(unique_labels)))
    color_map = {label: colors[i] for i, label in enumerate(unique_labels)}

    # Vẽ các điểm
    for label in unique_labels:
        mask = np.array(labels) == label
        ax.scatter(coords[mask, 0], coords[mask, 1], coords[mask, 2],
                  c=[color_map[label]], label=label, s=100, alpha=0.6,
                  edgecolors='black', linewidths=0.5)

    # Thêm label cho các điểm
    for i, word in enumerate(words):
        ax.text(coords[i, 0], coords[i, 1], coords[i, 2], word,
```

```

        fontsize=8, alpha=0.8, ha='center')

ax.set_xlabel('Component 1', fontsize=11, labelpad=10)
ax.set_ylabel('Component 2', fontsize=11, labelpad=10)
ax.set_zlabel('Component 3', fontsize=11, labelpad=10)
ax.set_title(title, fontsize=14, fontweight='bold', pad=20)
ax.legend(loc='upper right', fontsize=9, framealpha=0.9)
ax.grid(True, alpha=0.3)

# Điều chỉnh góc nhìn
ax.view_init(elev=20, azim=45)

plt.tight_layout()

# Lưu thành ảnh PNG nếu có đường dẫn
if save_path:
    try:
        os.makedirs(os.path.dirname(save_path), exist_ok=True)
        fig.savefig(save_path, dpi=150, bbox_inches='tight', facecolor='white')
        print(f"Đã lưu ảnh: {save_path}")
    except Exception as e:
        print(f"Lỗi khi lưu ảnh: {e}")

    return fig

# Tạo thư mục để Lưu ảnh
os.makedirs('results/3d_plots', exist_ok=True)

# Vẽ PCA 3D cho các model và Lưu ảnh
print("Word2Vec - PCA 3D:")
fig_w2v_pca_3d = plot_3d_interactive(w2v_pca_3d, w2v_words, w2v_labels,
                                     'Word2Vec Embeddings - PCA 3D',
                                     save_path='results/3d_plots/word2vec_pca_3d.png')
plt.show()

print("\nGloVe - PCA 3D:")
fig_glove_pca_3d = plot_3d_interactive(glove_pca_3d, glove_words, glove_labels,
                                       'GloVe Embeddings - PCA 3D',
                                       save_path='results/3d_plots/glove_pca_3d.png')
plt.show()

print("\nfastText - PCA 3D:")
fig_ft_pca_3d = plot_3d_interactive(ft_pca_3d, ft_words, ft_labels,
                                    'fastText Embeddings - PCA 3D',
                                    save_path='results/3d_plots/fasttext_pca_3d.png')
plt.show()


```

Word2Vec - PCA 3D:

Đã lưu ảnh: results/3d_plots/word2vec_pca_3d.png

Đã lưu ảnh: results/3d_plots/word2vec_pca_3d.png

Word2Vec Embeddings - PCA 3D




GloVe - PCA 3D:

Đã lưu ảnh: results/3d_plots/glove_pca_3d.png

Đã lưu ảnh: results/3d_plots/glove_pca_3d.png

GloVe Embeddings - PCA 3D




fastText - PCA 3D:

Đã lưu ảnh: results/3d_plots/fasttext_pca_3d.png

Đã lưu ảnh: results/3d_plots/fasttext_pca_3d.png

fastText Embeddings - PCA 3D



13. Trực quan hóa 3D với t-SNE (Interactive)

```
In [30]: # Vẽ t-SNE 3D cho các model và Lưu ảnh
print("Word2Vec - t-SNE 3D:")
fig_w2v_tsne_3d = plot_3d_interactive(w2v_tsne_3d, w2v_words, w2v_labels,
                                     'Word2Vec Embeddings - t-SNE 3D',
                                     save_path='results/3d_plots/word2vec_tsne_3d.

plt.show()

print("\nGloVe - t-SNE 3D:")
fig_glove_tsne_3d = plot_3d_interactive(glove_tsne_3d, glove_words, glove_labels,
                                     'GloVe Embeddings - t-SNE 3D',
                                     save_path='results/3d_plots/glove_tsne_3d.p

plt.show()

print("\nfastText - t-SNE 3D:")
```


```
fig_ft_tsne_3d = plot_3d_interactive(ft_tsne_3d, ft_words, ft_labels,
                                     'fastText Embeddings - t-SNE 3D',
                                     save_path='results/3d_plots/fasttext_tsne_3d.p
plt.show()
```

Word2Vec - t-SNE 3D:

Đã lưu ảnh: results/3d_plots/word2vec_tsne_3d.png

Đã lưu ảnh: results/3d_plots/word2vec_tsne_3d.png

Word2Vec Embeddings - t-SNE 3D




GloVe - t-SNE 3D:

Đã lưu ảnh: results/3d_plots/glove_tsne_3d.png

Đã lưu ảnh: results/3d_plots/glove_tsne_3d.png

GloVe Embeddings - t-SNE 3D




fastText - t-SNE 3D:

Đã lưu ảnh: results/3d_plots/fasttext_tsne_3d.png

Đã lưu ảnh: results/3d_plots/fasttext_tsne_3d.png

fastText Embeddings - t-SNE 3D



14. Heatmap - Ma trận tương đồng (Similarity Matrix)

```
In [20]: def plot_similarity_matrix(vectors, words, title):
        """
        Vẽ heatmap cho ma trận cosine similarity
        """
        # Tính cosine similarity matrix
        similarity_matrix = cosine_similarity(vectors)

        # Vẽ heatmap
        fig, ax = plt.subplots(figsize=(14, 12))
        sns.heatmap(similarity_matrix, annot=False, cmap='coolwarm',
                    xticklabels=words, yticklabels=words,
                    center=0, square=True, linewidths=0.5,
                    cbar_kws={'label': 'Cosine Similarity'})
```

```

ax.set_title(title, fontsize=14, fontweight='bold', pad=20)
plt.xticks(rotation=90, fontsize=8)
plt.yticks(rotation=0, fontsize=8)
plt.tight_layout()


return fig, similarity_matrix

# Chọn một subset nhỏ các từ để vẽ heatmap (để đọc hơn)
subset_words = ['king', 'queen', 'man', 'woman', 'computer', 'software',
                'happy', 'sad', 'cat', 'dog']

# Lấy vectors cho subset
w2v_subset_vectors, w2v_subset_words, _ = get_vectors_for_words(word2vec_model, sub

# Vẽ similarity matrix
fig_sim, sim_matrix = plot_similarity_matrix(w2v_subset_vectors, w2v_subset_words,
                                             'Word2Vec - Cosine Similarity Matrix')
plt.show()

```



15. So sanh PCA vs t-SNE

```

In [21]: # Vẽ so sánh side-by-side
fig, axes = plt.subplots(1, 2, figsize=(20, 8))

# PCA
unique_labels = list(set(w2v_labels))
colors = plt.cm.tab10(np.linspace(0, 1, len(unique_labels)))
color_map = {label: colors[i] for i, label in enumerate(unique_labels)}

for label in unique_labels:
    mask = np.array(w2v_labels) == label
    axes[0].scatter(w2v_pca_2d[mask, 0], w2v_pca_2d[mask, 1],
                    c=[color_map[label]], label=label, s=100, alpha=0.6, edgecolors=

for i, word in enumerate(w2v_words):
    axes[0].annotate(word, (w2v_pca_2d[i, 0], w2v_pca_2d[i, 1]),
                      fontsize=9, alpha=0.8, ha='center')

axes[0].set_title('PCA 2D - Word2Vec', fontsize=14, fontweight='bold')
axes[0].set_xlabel('PC1', fontsize=12)
axes[0].set_ylabel('PC2', fontsize=12)
axes[0].legend(loc='best')
axes[0].grid(True, alpha=0.3)


# t-SNE
for label in unique_labels:
    mask = np.array(w2v_labels) == label
    axes[1].scatter(w2v_tsne_2d[mask, 0], w2v_tsne_2d[mask, 1],
                    c=[color_map[label]], label=label, s=100, alpha=0.6, edgecolors=

for i, word in enumerate(w2v_words):
    axes[1].annotate(word, (w2v_tsne_2d[i, 0], w2v_tsne_2d[i, 1]),
                      fontsize=9, alpha=0.8, ha='center')

axes[1].set_title('t-SNE 2D - Word2Vec', fontsize=14, fontweight='bold')
axes[1].set_xlabel('t-SNE 1', fontsize=12)
axes[1].set_ylabel('t-SNE 2', fontsize=12)
axes[1].legend(loc='best')
axes[1].grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

```



16. Phân tích và đánh giá

So sánh các model embedding

```
In [22]: # Tính trung bình similarity score cho mỗi model
def analyze_model_similarities(model, test_words):
    """
    Phân tích similarity scores của model
    """
    similarities = []

    for word in test_words:
        if word in model:
            similar = model.most_similar(word, topn=10)
            scores = [score for _, score in similar]
            similarities.extend(scores)

    return {
        'mean': np.mean(similarities),
        'std': np.std(similarities),
        'min': np.min(similarities),
        'max': np.max(similarities)
    }

# Phan tich
test_words_sample = ['king', 'computer', 'happy', 'science', 'cat']

print("Phân tích Similarity Scores:")
print("=" * 80)

w2v_stats = analyze_model_similarities(word2vec_model, test_words_sample)
print("\nWord2Vec:")
for key, value in w2v_stats.items():
    print(f" {key}: {value:.4f}")

glove_stats = analyze_model_similarities(glove_model, test_words_sample)
print("\nGloVe:")
for key, value in glove_stats.items():
    print(f" {key}: {value:.4f}")
```

```
ft_stats = analyze_model_similarities(fasttext_model, test_words_sample)
print("\nfastText:")
for key, value in ft_stats.items():
    print(f" {key}: {value:.4f}")
```

Phân tích Similarity Scores:

=====

Word2Vec:

```
mean: 0.6473
std: 0.0631
min: 0.5422
max: 0.8099
```

GloVe:

```
mean: 0.6012
std: 0.0731
min: 0.4585
max: 0.8248
```

fastText:

```
mean: 0.7621
std: 0.0316
min: 0.7057
max: 0.8473
```

17. Kiểm tra Out-of-Vocabulary (OOV) Words

Test khả năng xử lý các từ không có trong vocabulary

```
In [23]: # Test với các từ OOV và misspelled words
oov_words = ['coronavirus', 'smartphone', 'deeplearning', 'chatbot', 'astronauts']
misspelled_words = ['computr', 'progrming', 'happyness', 'science']

print("Test Out-of-Vocabulary (OOV) Words:")
print("=" * 80)

print("\nCác từ có thể mới hoặc chưa có trong vocabulary:")
for word in oov_words:
    w2v = word in word2vec_model
    glv = word in glove_model
    ft = word in fasttext_model
    print(f"{word:20s} - Word2Vec: {w2v}, GloVe: {glv}, fastText: {ft}")

print("\nCác từ sai chính tả:")
for word in misspelled_words:
    w2v = word in word2vec_model
    glv = word in glove_model
    ft = word in fasttext_model
    print(f"{word:20s} - Word2Vec: {w2v}, GloVe: {glv}, fastText: {ft}")

# fastText có thể xử lý OOV words thông qua subwords
if not ft and hasattr(fasttext_model, 'get_vector'):
    try:
```

```
vec = fasttext_model.get_vector(word)
print(f" -> fastText vẫn có thể tạo vector cho '{word}' thông qua subw
except:
pass
```

Test Out-of-Vocabulary (OOV) Words:

=====

Các từ có thể mới hoặc chưa có trong vocabulary:

coronavirus	- Word2Vec: True, GloVe: True, fastText: True
smartphone	- Word2Vec: True, GloVe: True, fastText: True
deeplearning	- Word2Vec: False, GloVe: False, fastText: False
chatbot	- Word2Vec: True, GloVe: False, fastText: True
astronauts	- Word2Vec: True, GloVe: True, fastText: True

Các từ sai chính tả:

computr	- Word2Vec: False, GloVe: False, fastText: False
progrming	- Word2Vec: False, GloVe: False, fastText: False
happyness	- Word2Vec: True, GloVe: True, fastText: True
sciense	- Word2Vec: False, GloVe: False, fastText: False

18. Kết luận và nhận xét cá nhân

Tổng kết các phát hiện chính

Kết luận

1. Giảm chiều

- PCA: Nhanh, linear, giữ được global structure
- t-SNE: Chậm hơn, non-linear, tốt cho visualization, giữ được local structure

2. So sánh Model:

- **Word2Vec**: Hiệu quả, nhanh, nhưng không xử lý được OOV words
- **GloVe**: Tốt với global co-occurrence statistics
- **fastText**: Có thể xử lý OOV words thông qua subword information

3. Trực quan hóa:

- Các từ có nghĩa tương tự được nhóm lại gần nhau
- Các nhóm semantic rõ ràng trong không gian 2D/3D
- t-SNE cho kết quả trực quan tốt hơn PCA cho mục đích visualization

4. Tìm từ có ý nghĩa tương đương:

- Cả 3 model đều cho kết quả tốt trong việc tìm từ tương đồng
- Analogy tasks cho thấy embeddings nắm bắt được quan hệ semantic

Nhận xét và Đánh giá cá nhân

1. Về phương pháp triển khai:

- Sử dụng pre-trained embeddings giúp tiết kiệm thời gian và tài nguyên, không cần train từ đầu
- Code được tổ chức rõ ràng theo từng bước: load model → khảo sát → giảm chiều → visualization
- Sử dụng kết hợp cả PCA và t-SNE giúp so sánh được ưu nhược điểm của từng phương pháp
- Visualization 2D và 3D interactive (Plotly) giúp dễ dàng quan sát và tương tác với dữ liệu

2. Về kết quả quan sát:

PCA vs t-SNE:

- **PCA** giữ được cấu trúc toàn cục nhưng các cluster chưa tách biệt rõ ràng
- **t-SNE** cho kết quả visualization tốt hơn, các nhóm từ semantic được tách biệt rõ ràng
- PCA nhanh hơn đáng kể (< 1s vs ~10-30s với t-SNE)
- Khi giảm xuống 2D/3D, cả hai phương pháp đều mất đi một phần thông tin (explained variance của PCA chỉ ~15-20%)

So sánh Word2Vec, GloVe, fastText:

- **Word2Vec** cho kết quả tìm kiếm tương đồng tốt, đặc biệt với các từ phổ biến
- **GloVe** có vocabulary nhỏ hơn nhưng embeddings ổn định hơn do học từ global co-occurrence
- **fastText** linh hoạt nhất, có thể xử lý OOV words và typos
- Cả 3 model đều thể hiện tốt quan hệ semantic trong analogy tasks

Về clustering semantic:

- Các từ cùng nhóm (Royalty, Family, Technology...) được nhóm lại gần nhau rõ ràng
- Một số từ có thể xuất hiện ở vùng trung gian (ví dụ: 'prince' có thể gần cả 'man' và 'king')
- Similarity matrix cho thấy các từ đồng nghĩa có cosine similarity cao (> 0.5)

Lựa chọn embedding model:

- Dùng Word2Vec/GloVe cho tốc độ và hiệu quả với vocabulary có sẵn
- Dùng fastText khi cần xử lý từ mới, typos, hoặc ngôn ngữ có hình thái phức tạp

Lựa chọn phương pháp giảm chiều:

- PCA cho phân tích nhanh, khám phá sơ bộ
- t-SNE cho visualization